

潘子铭

物理 AI | 生成模型 | 多模态
Email: panziming@yonsei.ac.kr

TEL: (86) 17774158759 / (82) 010-8117-0744

EDUCATION

延世大学 (首尔) | QS Rank 42 | 本科
电子信息 (信息工程)

首尔, 韩国
2025 年 3 月-至今

EXPERIENCE

中石油集团 | 经济技术研究院 | 能源大数据中心
LLM 后训练实习

北京, 中国
2026 年 7 月-至今

- 多模态 agent 理解与推理, 记忆与个性化, 自然语言理解与生成
- 负责中石油集团“昆仑问策”agent 后训练, 设计强化学习训练框架与奖励机制, 主导模型能力评估与迭代优化

清华大学 | 智能产业研究院 (AIR)
科研实习

北京, 中国
2026 年 3 月-2026 年 7 月

- 扩散模型训练与推理系统优化
- 大规模跨尺度科学智能模型

PROJECTS

RethinkDMD: 稀疏化与低秩适配统一的高效 Fake Score 蒸馏

2026 年 8 月

- DMD2 类蒸馏方法中, fake score network 与教师同容量同构, 需要独立维护一整套 UNet 的参数、优化器状态与前反向开销, 这部分开销在训练全程反复发生, 是蒸馏算力的主要瓶颈之一。我们提出 RethinkDMD, 将稀疏化更新与低秩适配技术统一应用于 fake score network: 用低秩适配器承接对 student 当前分布的在线拟合, 只训练与教师共享主干的一小部分参数; 配合稀疏化的计算路径, 去除对 fake UNet 的冗余全量前反向。fake score 由此从与教师等重的第二套网络, 变为轻量、可高频更新的在线适配层。该设计带来两个直接收益: 训练侧算力与显存开销显著下降, 蒸馏整体提速; 同时轻量化换来的高频、低延迟在线更新, 使 fake score 更紧跟 student 分布的漂移, real/fake score 之差给出的蒸馏梯度更准, 蒸馏质量同步提升。

ShapeSP: 面向 Diffusion Transformer 服务的 Cache/稀疏度与序列并行度联合调度

2026 年 8 月

- Diffusion Transformer 多卡服务中, Cache-DiT 的 full/cached 去噪阶段与稀疏 attention 会让每步算力随 shape 大幅波动, 而 Sequence Parallelism (SP) degree 通常在请求生命周期内固定, latency 最优点和 GPU-ms 最优点因此系统性冲突, 重步并行度不够、轻步又被过度切分。我们提出 ShapeSP, 在 step/layer-band 边界做粗粒度弹性 SP 切换, 同一 SP degree 内用 head permutation 和 partition plan 处理层内变化, 把状态迁移成本摊销到多个层或多个 step 上, 避免逐层切换让迁移开销吞掉收益。在真实多卡 PixArt 在线服务闭环上验证: 低负载下动态与静态 SP 基本持平, 迁移成本会侵蚀掉小部分理论收益; 负载升高后动态调度的容量优势显著释放, QPS 4.0 相对固定 SP 提升 goodput 5.6%, QPS 4.5 提升 24.8% (固定 SP 策略在高负载下率先崩溃), 跨 7 个 QPS 点验证了这一趋势, 收益来自计算并行度而非迁移优化本身。

LongWMBench: 面向流式视频世界模型的长时记忆一致性评测

2026 年 7 月

- 与阿里巴巴 Happy Oyster 团队联合开展, 构建面向流式视频生成世界模型的长时记忆一致性评测基准。模型以历史生成片段、文本目标及事件条件为上下文, 按时间块持续 rollout; 任务通过物体重现、状态回溯、跨场景交互与因果延续, 检验长期记忆是否被保留并在后续生成中正确调用。设计 agent 驱动的交互式评测: agent 在开放视频环境中完成多步探索、操控与目标驱动任务, 结合轨迹成功率、状态一致性和跨块时空连续性, 诊断模型在记忆遗忘、状态漂移与误差累积上的失效模式。

AtomWorld-Mirror: 沿关键演化主干宏步推进的原子模拟世界模型

2026 年 3 月

- 材料模拟中导致结构演化的关键事件往往是稀疏且随机出现的。使用经典方法进行模拟时, 往往还未到达决定性状态, 算力预算就被无意义事件消耗殆尽。因此我们提出 AtomWorld-Mirror, 一种面向长时程材料模拟任务的原子世界宏步建模方法, 通过在 latent space 中学习材料演化的关键主干, 并在关键主干上宏步推进演化, 以替代经典方法的逐微事件回放。Mirror 在每个宏步联合预测物理可达的稀疏晶格编辑、累计物理时间和下一潜在状态, 并加以物理机制约束, 在保持结构与时间语义的同时实现事件级模拟加速。

PUBLICATIONS

[1] Pan, Z., Zhang, R., Han, H., Chen, Y., Zhang, Y., Cao, T., Liu, Y., & Li, K. (2026). AtomWorld-Mirror: Macro-Step World Modeling of Critical Evolution Backbones for Materials Dynamics. Conference on Neural Information Processing Systems, NeurIPS 2026. (一作, Under Review)